Pandas实例

1.基本操作

pandas库的版本

构造DataFrame

数据基本信息

选择列

选择行和列

数据筛选

修改元素值

列求和

分组求和

增加行

删除行

个数统计

列排序

数据转换map

数据替换replace

数据透视表

2.搭配操作

列元素去重

数据去重

列相减

极值索引

删除重复项

数据分段分组

3.数据清洗

构造杂乱数据

插值处理

字符串分割

标准化字符串

数据合并

文本匹配

列表展开

1.基本操作

pandas库的版本

In [1]:
```
import numpy as np
import pandas as pd
import warnings

# 打印出pandas 库的版本信息
pd.__version__
```

Out[1]: '1.4.1'

构造DataFrame

In [2]:
```
# 数据字典data 以及列表格式的标签数据labels
data = {'animal': ['cat', 'cat', 'snake', 'dog', 'dog', 'cat', 'snake', 'cat', 'dog',
        'age': [2.5, 3, 0.5, np.nan, 5, 2, 4.5, np.nan, 7, 3],
        'visits': [1, 3, 2, 3, 2, 3, 1, 1, 2, 1],
        'priority': ['yes', 'yes', 'no', 'yes', 'no', 'no', 'no', 'yes', 'no', 'no']}

labels = ['a', 'b', 'c', 'd', 'e', 'f', 'g', 'h', 'i', 'j']
```

In [3]:
```
df = pd.DataFrame(data, index=labels)
df
```

Out[3]:

	animal	age	visits	priority
a	cat	2.5	1	yes
b	cat	3.0	3	yes
c	snake	0.5	2	no
d	dog	NaN	3	yes
e	dog	5.0	2	no
f	cat	2.0	3	no
g	snake	4.5	1	no
h	cat	NaN	1	yes
i	dog	7.0	2	no

	animal	age	visits	priority
j	dog	3.0	1	no

数据基本信息

In [4]:
```
df.info()  # 数据相关的基本信息
df.describe()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 10 entries, a to j
Data columns (total 4 columns):
 #   Column    Non-Null Count  Dtype  
---  ------    --------------  -----  
 0   animal    10 non-null     object 
 1   age       8 non-null      float64
 2   visits    10 non-null     int64  
 3   priority  10 non-null     object 
dtypes: float64(1), int64(1), object(2)
memory usage: 400.0+ bytes
```

Out[4]:

	age	visits
count	8.000000	10.000000
mean	3.437500	1.900000
std	2.007797	0.875595
min	0.500000	1.000000
25%	2.375000	1.000000
50%	3.000000	2.000000
75%	4.625000	2.750000
max	7.000000	3.000000

选择列

In [5]:
```
# 从 DataFrame `df` 选择标签为 `animal` 和 `age` 的列
df[["animal","age"]]
```

Out[5]:

	animal	age
a	cat	2.5
b	cat	3.0
c	snake	0.5
d	dog	NaN
e	dog	5.0
f	cat	2.0
g	snake	4.5
h	cat	NaN
i	dog	7.0
j	dog	3.0

In [6]:
```
df.loc[:,["animal","age"]]
```

Out[6]:

	animal	age
a	cat	2.5
b	cat	3.0
c	snake	0.5
d	dog	NaN
e	dog	5.0
f	cat	2.0
g	snake	4.5
h	cat	NaN
i	dog	7.0
j	dog	3.0

选择行和列

In [7]:
```
# 在 [3, 4, 8] 行中，列为 ['animal', 'age'] 的数据
df.loc[df.index[[3, 4, 8]], ['animal', 'age']]
```

Out[7]:

	animal	age
d	dog	NaN
e	dog	5.0
i	dog	7.0

In [8]:
```
df.iloc[[3, 4, 8], [0, 1]]
```

Out[8]:

	animal	age
d	dog	NaN
e	dog	5.0
i	dog	7.0

数据筛选

In [9]:
```
# 选择列```visits``` 大于 1 的行
df[df['visits'] > 1]
```

Out[9]:

	animal	age	visits	priority
b	cat	3.0	3	yes
c	snake	0.5	2	no
d	dog	NaN	3	yes
e	dog	5.0	2	no

	animal	age	visits	priority
f	cat	2.0	3	no
i	dog	7.0	2	no

In [10]:
```
# 选择 `age` 为缺失值的行
df[df['age'].isnull()]
```

Out[10]:

	animal	age	visits	priority
d	dog	NaN	3	yes
h	cat	NaN	1	yes

In [11]:
```
# 选择 `animal` 是cat且`age` 小于 3 的行
df[(df['animal'] == 'cat') & (df['age'] < 3)]
```

Out[11]:

	animal	age	visits	priority
a	cat	2.5	1	yes
f	cat	2.0	3	no

In [12]:
```
# 选择 `age` 在 2 到 4 之间的数据（包含边界值）
df[df['age'].between(2, 4)]
```

Out[12]:

	animal	age	visits	priority
a	cat	2.5	1	yes
b	cat	3.0	3	yes
f	cat	2.0	3	no
j	dog	3.0	1	no

修改元素值

In [13]:
```
# 将 'f' 行的 `age` 改为 1.5
df.loc['f', 'age'] = 1.5
```

列求和

In [14]:
```
# 对 `visits` 列的数据求和
df['visits'].sum()
```

Out[14]:
```
19
```

分组求和

In [15]:
```
# 计算每种 `animal` `age` 的和
df.groupby('animal')['age'].sum()
```

Out[15]:
```
animal
cat    7.0
```

```
dog      15.0
snake     5.0
Name: age, dtype: float64
```

增加行

In [16]:
```
# 新增一行数据 k，数据自定义
df.loc['k'] = [5.5, 'dog', 'no', 2]
df
```

Out[16]:

	animal	age	visits	priority
a	cat	2.5	1	yes
b	cat	3.0	3	yes
c	snake	0.5	2	no
d	dog	NaN	3	yes
e	dog	5.0	2	no
f	cat	1.5	3	no
g	snake	4.5	1	no
h	cat	NaN	1	yes
i	dog	7.0	2	no
j	dog	3.0	1	no
k	5.5	dog	no	2

删除行

In [17]:
```
# 删除新追加的 k 行
df = df.drop('k', axis=0)
df
```

Out[17]:

	animal	age	visits	priority
a	cat	2.5	1	yes
b	cat	3.0	3	yes
c	snake	0.5	2	no
d	dog	NaN	3	yes
e	dog	5.0	2	no
f	cat	1.5	3	no
g	snake	4.5	1	no
h	cat	NaN	1	yes
i	dog	7.0	2	no
j	dog	3.0	1	no

个数统计

In [18]:
```
# 统计每种 `animal` 的个数
```

```
df['animal'].value_counts()
```

Out[18]:
```
cat      4
dog      4
snake    2
Name: animal, dtype: int64
```

列排序

In [19]:
```
# 先根据 `age` 降序排列，再根据 `visits` 升序排列
df.sort_values(by=['age', 'visits'], ascending=[False, True])  # 默认升序
```

Out[19]:

	animal	age	visits	priority
i	dog	7.0	2	no
e	dog	5.0	2	no
g	snake	4.5	1	no
j	dog	3.0	1	no
b	cat	3.0	3	yes
a	cat	2.5	1	yes
f	cat	1.5	3	no
c	snake	0.5	2	no
h	cat	NaN	1	yes
d	dog	NaN	3	yes

数据转换map

In [20]:
```
# 将 `priority` 列的 `yes` 和 `no` 用 `True` 和 `False` 替换
df['priority'] = df['priority'].map({'yes': True, 'no': False})  # 使用map方法将字符
df
```

Out[20]:

	animal	age	visits	priority
a	cat	2.5	1	True
b	cat	3.0	3	True
c	snake	0.5	2	False
d	dog	NaN	3	True
e	dog	5.0	2	False
f	cat	1.5	3	False
g	snake	4.5	1	False
h	cat	NaN	1	True
i	dog	7.0	2	False
j	dog	3.0	1	False

数据替换replace

In [21]:
```
# 将 `animal` 列的 `snake` 用 `python` 替换
```

```
df['animal'] = df['animal'].replace('snake', 'python')
df
```

Out[21]:

	animal	age	visits	priority
a	cat	2.5	1	True
b	cat	3.0	3	True
c	python	0.5	2	False
d	dog	NaN	3	True
e	dog	5.0	2	False
f	cat	1.5	3	False
g	python	4.5	1	False
h	cat	NaN	1	True
i	dog	7.0	2	False
j	dog	3.0	1	False

In [22]:

```
# df['animal'] = df['animal'].map({'python': 'snake'})  # map未写完类别，其余的都被置
# df
```

数据透视表

In [23]:

```
# 对于每种 `animal` 和 `visit`，求出平均年龄。换句话说，每一行都是动物，每一列都是访问
df.pivot_table(index='animal', columns='visits', values='age', aggfunc='mean')
```

Out[23]:

visits	1	2	3
animal			
cat	2.5	NaN	2.25
dog	3.0	6.0	NaN
python	4.5	0.5	NaN

2.搭配操作

In [24]:

```
df = pd.DataFrame({'A': [1, 2, 2, 3, 4, 5, 5, 5, 6, 7, 7]})
df
```

Out[24]:

	A
0	1
1	2
2	2
3	3
4	4
5	5

	A
6	5
7	5
8	6
9	7
10	7

列元素去重

In [25]:
```
# `df`中`A`列出现的元素的唯一值（即：出现过的所有元素的集合）
df['A'].unique()
```

Out[25]:
```
array([1, 2, 3, 4, 5, 6, 7], dtype=int64)
```

数据去重

In [26]:
```
# 将`df`进行数据降重
df.drop_duplicates(['A'])  # 只保留第一次出现的行
```

Out[26]:

	A
0	1
1	2
3	3
4	4
5	5
8	6
9	7

列相减

In [27]:
```
# 给定一组随机数据
df = pd.DataFrame(np.random.random(size=(5, 3)))
df
```

Out[27]:

	0	1	2
0	0.374783	0.263837	0.992780
1	0.479938	0.981076	0.838327
2	0.099663	0.022200	0.671596
3	0.954756	0.485253	0.523484
4	0.857240	0.043054	0.138441

In [28]:
```
# 使每个元素减去所在行的平均值
df.sub(df.mean(axis=1), axis=0)
```

Out[28]:

	0	1	2
0	-0.169017	-0.279963	0.448980
1	-0.286509	0.214629	0.071880
2	-0.164823	-0.242287	0.407110
3	0.300258	-0.169245	-0.131013
4	0.510995	-0.303191	-0.207804

极值索引

In [29]:
```
df = pd.DataFrame(np.random.random(size=(5, 10)), columns=list('abcdefghij'))
df
```

Out[29]:

	a	b	c	d	e	f	g	h	i	j
0	0.567944	0.921168	0.521974	0.583570	0.178107	0.903390	0.261774	0.836178	0.726512	0.586562
1	0.279541	0.242886	0.600041	0.520493	0.710574	0.654514	0.366569	0.540094	0.345685	0.516206
2	0.310480	0.386638	0.362324	0.292853	0.757898	0.217559	0.394976	0.232218	0.297622	0.499301
3	0.887586	0.049991	0.949864	0.731598	0.573696	0.145510	0.041429	0.615991	0.524794	0.811569
4	0.245327	0.642334	0.937530	0.272604	0.599459	0.966564	0.727655	0.300235	0.139796	0.749208

In [30]:
```
# 返回下列`df`数字总和最小那列的标签
# Pandas 里面的 idxmin 、idxmax函数与Numpy中 argmax、argmin 用法大致相同
df.sum().idxmin()  # idxmin()返回第一次出现的最小/最大值的索引
```

Out[30]: 'g'

In [31]:
```
df.columns[np.argmin(df.sum())]  # argmin返回第一次出现的最小/最大值的索引
```

Out[31]: 'g'

删除重复项

In [32]:
```
df = pd.DataFrame(np.random.randint(0, 2, size=(10, 3)))
df
```

Out[32]:

	0	1	2
0	0	1	1
1	1	1	0
2	0	1	1
3	1	1	1
4	1	1	0
5	1	0	1
6	1	0	1

	0	1	2
7	1	0	1
8	1	0	0
9	0	0	0

In [33]:
```
# 计算一个 DataFrame 有多少不重复的行
df.drop_duplicates(keep=False)  # keep=False 删除所有重复项
```

Out[33]:

	0	1	2
3	1	1	1
8	1	0	0
9	0	0	0

In [34]:
```
len(df.drop_duplicates(keep=False))
```

Out[34]: 3

数据分段分组

In [35]:
```
df = pd.DataFrame(np.random.RandomState(1).randint(1, 4, size=(10, 2)), columns = ["A
df
```

Out[35]:

	A	B
0	2	1
1	1	2
2	2	1
3	1	2
4	1	2
5	1	3
6	2	3
7	1	3
8	2	3
9	1	1

In [36]:
```
# 产生一个随机状态种子 np.random.RandomState(1).randint 左闭右开
df = pd.DataFrame(np.random.RandomState(1).randint(0, 101,
                  size=(100, 2)),
                  columns = ["A", "B"])
df
```

Out[36]:

	A	B
0	37	12

	A	B
1	72	9
2	75	5
3	79	64
4	16	1
...	...	...
95	71	53
96	69	36
97	21	40
98	77	91
99	49	47

100 rows × 2 columns

In [37]:
```
# 对 A 进行分段分组（i.e. (0, 10], (10, 20], ...），求每组内 B 的和。
df.groupby(pd.cut(df['A'], np.arange(0, 101, 10)))['B'].sum()  # pd.cut数据分段
```

Out[37]:
```
A
(0, 10]       752
(10, 20]      475
(20, 30]      684
(30, 40]      161
(40, 50]      384
(50, 60]      839
(60, 70]      428
(70, 80]      615
(80, 90]      358
(90, 100]     300
Name: B, dtype: int32
```

3.数据清洗

构造杂乱数据

In [38]:
```
df = pd.DataFrame({'From_To': ['LoNDon_paris', 'MAdrid_miLAN', 'londON_StockhOlm',
                               'Budapest_PaRis', 'Brussels_londOn'],
                   'FlightNumber': [10045, np.nan, 10065, np.nan, 10085],
                   'RecentDelays': [[23, 47], [], [24, 43, 87], [13], [67, 32]],
                        'Airline': ['KLM(!)', '<Air France> (12)', '(British Airways. )',
                                    '12. Air France', '"Swiss Air"']})
df
```

Out[38]:

	From_To	FlightNumber	RecentDelays	Airline
0	LoNDon_paris	10045.0	[23, 47]	KLM(!)
1	MAdrid_miLAN	NaN	[]	<Air France> (12)
2	londON_StockhOlm	10065.0	[24, 43, 87]	(British Airways.)
3	Budapest_PaRis	NaN	[13]	12. Air France
4	Brussels_londOn	10085.0	[67, 32]	"Swiss Air"

插值处理

FlightNumber列中的某些值缺失（它们是NaN）。

这些数字是有规律的，即每行增加 10，因此 NaN 需要放置 10055 和 10075。

修改 df 以填充这些缺失的数字并使该列成为整数列（而不是浮点列）

df.interpolate()

DataFrame.interpolate(method='linear', axis=0, limit=None, inplace=False, limit_direction='forward', limit_area=None, downcast=None, **kwargs)

method插值方式：

nearest：最邻近插值法

zero：阶梯插值

slinear、linear：线性插值

quadratic、cubic：2、3阶B样条曲线插值

In [39]:
```
df['FlightNumber'] = df['FlightNumber'].interpolate().astype(int)  # 插值函数
df
```

Out[39]:

	From_To	FlightNumber	RecentDelays	Airline
0	LoNDon_paris	10045	[23, 47]	KLM(!)
1	MAdrid_miLAN	10055	[]	<Air France> (12)
2	londON_StockhOlm	10065	[24, 43, 87]	(British Airways.)
3	Budapest_PaRis	10075	[13]	12. Air France
4	Brussels_londOn	10085	[67, 32]	"Swiss Air"

字符串分割

From_To列作为两个单独的列会更好！

拆分下划线分隔符 _ 前后的每个字符串. 将其拆分成两列，

存放在一个名为"temp"的临时 DataFrame，将列名 'From' 和 'To' 分配给这个临时DataFrame.

In [40]:
```
temp = df['From_To'].str.split('_', expand=True)
temp.columns = ['From', 'To']
temp
```

Out[40]:

	From	To
0	LoNDon	paris
1	MAdrid	miLAN
2	londON	StockhOlm
3	Budapest	PaRis

	From	To
4	Brussels	londOn

标准化字符串

注意城市名称的大小写是混合在一起的。

只有第一个字母是大写的（例如“londON”应该变成“London”。）

In [41]:
```
temp['From'] = temp['From'].str.capitalize()
temp['To'] = temp['To'].str.capitalize()
temp
```

Out[41]:

	From	To
0	London	Paris
1	Madrid	Milan
2	London	Stockholm
3	Budapest	Paris
4	Brussels	London

数据合并

将 From_To 列从 df 中删去，将 temp 处理好的数据合并到 df 中

In [42]:
```
df = df.drop('From_To', axis=1)
df = df.join(temp)
df
```

Out[42]:

	FlightNumber	RecentDelays	Airline	From	To
0	10045	[23, 47]	KLM(!)	London	Paris
1	10055	[]	<Air France> (12)	Madrid	Milan
2	10065	[24, 43, 87]	(British Airways.)	London	Stockholm
3	10075	[13]	12. Air France	Budapest	Paris
4	10085	[67, 32]	"Swiss Air"	Brussels	London

文本匹配

只提取航空公司名称。

在 AirLine 列中，您可以看到航空公司名称周围出现了一些额外的符号。

例如'(British Airways.)'应该变成'British Airways'.

In [43]:
```
df['Airline'] = df['Airline'].str.extract('([a-zA-Z\s]+)', expand=False).str.strip()
df
```

Out[43]:

	FlightNumber	RecentDelays	Airline	From	To

	FlightNumber	RecentDelays	Airline	From	To
0	10045	[23, 47]	KLM	London	Paris
1	10055	[]	Air France	Madrid	Milan
2	10065	[24, 43, 87]	British Airways	London	Stockholm
3	10075	[13]	Air France	Budapest	Paris
4	10085	[67, 32]	Swiss Air	Brussels	London

列表展开

在 RecentDelays 列中，值已作为列表输入到 DataFrame 中。我们希望每个第一个值在它自己的列中，每个第二个值在它自己的列中，依此类推。如果没有第 N 个值，则该值应为 NaN。

将 Series 列表展开为名为 的 DataFrame delays，重命名列delay_1，delay_2等等，并将不需要的 RecentDelays 列替换df为delays

In [44]:
```
delays = df['RecentDelays'].apply(pd.Series)
delays
```

```
C:\Users\29511_orbf8\AppData\Local\Temp\ipykernel_54344\139781484.py:1: FutureWarning:
The default dtype for empty Series will be 'object' instead of 'float64' in a future v
ersion. Specify a dtype explicitly to silence this warning.
  delays = df['RecentDelays'].apply(pd.Series)
```

Out[44]:

	0	1	2
0	23.0	47.0	NaN
1	NaN	NaN	NaN
2	24.0	43.0	87.0
3	13.0	NaN	NaN
4	67.0	32.0	NaN

In [45]:
```
delays.columns = ['delay_{}'.format(n) for n in range(1, len(delays.columns)+1)]  #
df = df.drop('RecentDelays', axis=1).join(delays)  # 将新的列加入到原始数据中
df
```

Out[45]:

	FlightNumber	Airline	From	To	delay_1	delay_2	delay_3
0	10045	KLM	London	Paris	23.0	47.0	NaN
1	10055	Air France	Madrid	Milan	NaN	NaN	NaN
2	10065	British Airways	London	Stockholm	24.0	43.0	87.0
3	10075	Air France	Budapest	Paris	13.0	NaN	NaN
4	10085	Swiss Air	Brussels	London	67.0	32.0	NaN